



**Kauno technologijos universitetas**

Informatikos fakultetas

**Kompiuterinės regos metodų taikymas automatiniam  
pažeistos miško medžių lajos (lapų) klasifikavimui**

T000M241 „Tiriamasis projektas 1“, Projektavimo metodologijų ir technologijų  
analizės ataskaita

**Tomas Poška**

Studentas

**dr. Rytis Maskeliūnas**

Dėstytojas

**Kaunas, 2023**

## **Turinys**

Paveikslų sąrašas .....	3
Santrumpų ir terminų sąrašas .....	4
Įvadas.....	5
1. Temos aktualumas .....	6
2. Probleminė sritis .....	7
3. Egzistuojantys sprendimai .....	9
4. Konvoliuciniai neuroniniai tinklai.....	16
5. Išvados .....	19
Literatūros sąrašas .....	20

## Paveikslų sąrašas

pav. 1 Pušų defoliacijos 0-3 klasės.....	7
pav. 2 Sudėtingų klasifikavimo atvejų pavyzdžiai .....	8
pav. 3 Atlikto tyrimo duomenų kiekis suskirstytas pagal medžio rūšį.....	9
pav. 4 Žmonių ekspertų ir CNN medžių defoliacijos nustatymo rezultatai .....	10
pav. 5 3D modelių, kameros ir kampų, aukščio nustatymų.....	11
pav. 6 Atlikto tyrimo segmentavimo ir defoliacijos įvertinimų palyginimai pritaikius <i>RTCLE</i> ir <i>TSCLR</i> apmokymo modelius.....	11
pav. 7 Daugiastulpelinio konvoliucinio neuroninio tinklo struktūra.....	12
pav. 8 Žmonių minios tankio nustatymo sistemos struktūrinė schema .....	13
pav. 9 Medžių klasifikavimo sistemos struktūrinė schema .....	14
pav. 10 Pagrindinės konvoliucinių neuroninių tinklų architektūros dalys .....	16
pav. 11 Trys <i>CNN</i> aktyvavimo funkcijos: sigmoidinė kairėje, tiesinė vienetų viduryje ir parametrizuota ReLU dešinėje .....	17

## Santrumpų ir terminų sąrašas

### Santrumpos:

Doc. – docentas;

Lekt. – lektorius;

Prof. – profesorius.

### Terminai:

**Defoliacija** – priešlaikinis medžių lapų ar spyglių kritimas.

**Laja** - sumedėjusių augalų (medžių, krūmų) viršutinė dalis, esanti virš kamieno. Lają sudaro šakų ir lapų visuma.

**Fotogrametrija** – geodezijos šaka, iš fotografinių nuotraukų nustatanti objektų formą, matmenis, padėtį.

## **Ivadas**

Dokumentas yra Programų sistemų inžinerijos magistratūros disciplinos „Tiriamasis projektas 1“ (projektas „Kompiuterinės regos metodų taikymas automatiniam pažeistos miško medžių lajos (lapų) klasifikavimui“) ataskaita. Dokumento tikslas – apibūdinti tyrimo tikslus, apibendrinti atliktą literatūros analizę, pasirengti projekto reikalavimų specifikavimui, projektavimui, susipažinti su užsakymo taikymo sritimi, pasauliniais pasiekimais taikomojoje srityje.

Šiame darbe bus gilinamasi į kompiuterinės regos metodų taikymą sprendžiant automatinio pažeistos miško medžių lajos (lapų) klasifikavimo problemą. Naudojant tradicinių kompiuterinės regos algoritmų ir naujausių gilaus mokymosi metodų derinį, tyrimu siekiama sukurti patikimą ir tikslią sistemą, skirtą automatizuotam ligų aptikimui ir klasifikavimui miško ekosistemose. Tyrimo metu bus analizuojami išsamūs miško vaizdų duomenų rinkiniai, kuriuose gali būti užfiksuotos įvairios medžių rūšys, ligų tipai ar kiti parametrai. Naudojant pažangius vaizdų apdorojimo metodus ir konvoliucinius neuroninius tinklus (CNN), gali būti siekiama sukurti patikimą modelį, skirtą nustatyti ir klasifikuoti medžių ligas ar kitus aspektus pagal vizualinius požymius. Tyrimo metu bus analizuojami anksčiau atlikti susiję tyrimai, taip pat, kitų sričių tyrimai, kurių sprendimų metodus galima būtų taikyti klasifikavimo problemai spręsti, nagrinėjami jų sprendimai, tobulinimo ir pritaikymo galimybės. Tyrimas prisideda prie ankstyvojo ligų nustatymo ir stebėsenos miškuose pažangos, prie tvarios miškotvarkos ir skatina vertingų ekosistemų išsaugojimą.

Raktiniai žodžiai: Medžių ligų nustatymas, miško ekosistemos, kompiuterinė rega, dirbtinis intelektas, konvoliuciniai neuroniniai tinklai, klasifikavimas.

Keywords: Tree disease detection, forest ecosystems, computer vision, artificial intelligence, convolutional neural networks, CNN, classification.

## 1. Temos aktualumas

Miškai yra svarbi planetos ekosistemos dalis. Šiandien globalinės problemos, tokios kaip, globalinis atšilimas, šiltnamio efektas, oro užterštumas yra kaip niekad aktualios. Miškai ne tik prisideda prie šių problemų sprendimo – gerina oro kokybę, išskiria deguonį ir kt., bet ir teikia kitas neįkainojamas naudas kaip biologinė įvairovė – miškai teikia prieglobstį ir maistą daugeliui laukinių gyvūnų ir augalų rūšių; žmonėms, miškai yra ne tik poilsio praleidimo vieta, bet ir svarbi ekonimikos dalis. Lietuvoje, miškai yra viena pagrindinių kraštovaizdžio dalių, 2020 metais, miškas sudarė 33.7% viso šalies ploto [1]. Tuo pat metu, medienos bei jos gaminių eksportas siekė 11.7% viso šalies eksporto [2]. Miškų tvarkymas yra svarbus ne tik dėl aplinkosauginių priežasčių, bet ypač dėl medienos gamybos. Kenkėjų pažeisti medžiai teikia mažiau kokybiškos medienos, ji yra pigesnė ir mažiau naudinga [3]. Todėl miškų klestėjimas yra svarbus ekologiškai ir ekonomiškai.


Europoje miškų sveikatos būklė yra gera – 2020 metais, vidutinė visų rūšių miško medžių lajų defoliacija Europoje buvo 23.3% [4]. Nepaisant to, reikia atkreipti dėmesį į galimas medžių ligas, kurios gali atsirasti dėl įvairių priežasčių ir plisti labai greitai. Jei dominuoja tam tikros rūšies medžiai, pavojingos ligos gali sparčiai plisti. Todėl būtų aktualu kurti sistemą, kuri leistų greitai ir efektyviai aptikti medžių ligas ankstyvose jų stadijose. Tai padėtų išsaugoti miškų sveikatą ir išvengti galimų ekosistemų sutrikimų.

## 2. Probleminė sritis

Aptikti miško medžių ligas ankstyvojoje stadijoje yra svarbi, bet sudėtinga užduotis. Medžio laja yra pagrindinis miško medžių komponentas, kuriuo galima nustatyti medžio sveikatos būklę [5]. Medžio lajos defoliacija yra dažniausiai naudojamas matas nustatyti medžio sveikatą [6].

Lajų defoliacija vertinama 5 % gradacija vizualiai nustatant medžio lapijos nuostolius, lyginant juos su etaloniniu medžiu. Visiškai sveiko (turinčio visą lapiją) medžio defoliacija prilyginama 0%, o nudžiūvusio – 100%. Pagal defoliaciją medžiai skirstomi į 5 klases [7] (1 pav):

0. Santykinai sveiki medžiai (defoliacija 0–10 %);
1. Menkos defoliacijos (15–25 %);
2. Vidutinės defoliacijos (30–60 %);
3. Didelės defoliacijos (65–95 %);
4. Žuvę medžiai (100 %).



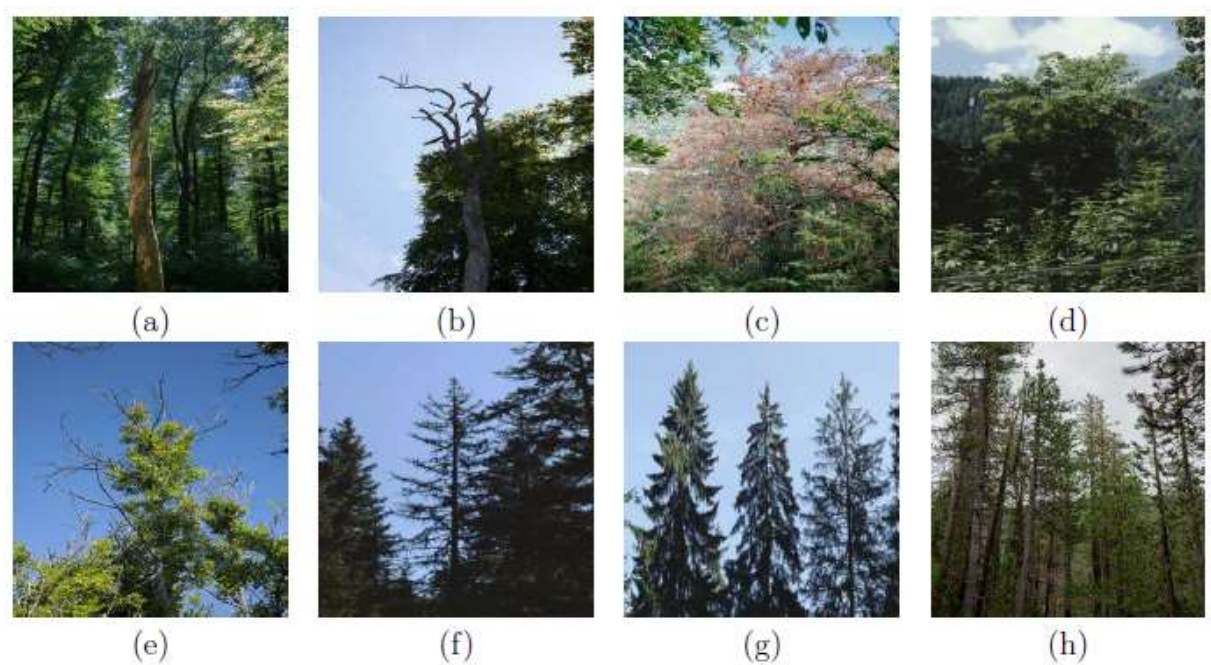
pav. 1 Pušų defoliacijos 0-3 klasės [8]

Medžio lapų defoliaciją gali lemti skirtingos priežastys, įskaitant ligas, kenkėjus, oro sąlygas, todėl yra svarbu identifikuoti defoliacijos stadijas ir jos progresavimą, siekiant veiksmingai įsikišti, nustatant konkrečias priežastis. Medžio defoliaciją gali lemti daug faktorių. Didelę įtaką medžių viršūnių būklei turi natūralūs veiksniai pvz. medžių senėjimas [7]. Todėl yra netikslinga mėginti paaiškinti defoliaciją remiantis tik vienu veiksniu, pavyzdžiui, oro tarša, be papildomų įrodymų. Aplinkos sąlygų įtakos ir toleruotino defoliacijos lygio negalima tiksliai įvertinti kiekybiškai, pažeistų medžių negalima atskirti nuo sveikų tik pagal tam tikrą defoliacijos lygio slenkstį, t.y. 25% medžio defoliacijos riba nebūtinai nustato, kad medis yra pažeistas fiziologiškai [9]. Kita problema, nustatant medžių sveikatos būklę vadovaujantis defoliacija yra žmogiškasis faktorius. Medžio viršūnės tankumas yra nespecifiškas simptomas, kuris negali neginčytinai paaiškinti faktinių miško pažeidimų priežasčių. Kadangi, lajų sveikatos vertinimai yra subjektyvūs ir charakteristikos yra grubios, gali atsirasti rimtų klaidų ir klausimų dėl miško sveikatos tendencijų patikimumo [10]. Taigi, nustatyti medžių sveikatos būklę yra sudėtinga užduotis, reikalaujanti detalaus stebėjimo ir įvairiapusės analizės.

Vis daugiau tyrimų yra atliekama siekiant kompiuterizuoti miško medžių sveikatos įvertinimo problemą, siekiant pigiau, efektyviau ir tiksliau nustatyti medžių ligas. Fotogrametrija ir nuotoliniai jutikliai yra papildomos priemonės šiuolaikinėje miškininkystėje, kurios yra dažnai naudojamos miško vertinimuose, analizuojant medynų augaliją, stebint gamtos nelaimės atvejus, matuojant

medžio viršūnių dangos plotą, biologinę įvairovę ir kituose panaudojimo atvejuose [3]. Fotogrametrinių ir nuotolinio stebėjimo duomenų analizę galima atlikti automatiškai, naudojant kompiuterinę regą ar gilųjį mokymą. Yra atliktų tyrimų ir sprendimų, kurie pasitelkia mašininį mokymą kaip klasifikavimo įrankį medžių sveikatos vertinime miškuose. Tačiau, kompiuterizuojant šią problemą, t.y. siekiant automatizuoti pažeistų medžių lajų klasifikavimą susiduriama su šiomis galimomis problemomis:

- Sudėtingas medžio atskyrimas nuo aplinkos (kitų medžių);
- Medžiais skiriasi rūšimis, aukščiu, forma, spalva;
- Skalės nustatymas;
- Medžio lapų tankumas nuotraukoje gali skirtis nuo kampo, kuriuo buvo fotografuojama [11];
- Sezoniškumas – medžių išvaizda gali keistis skirtingais metų laikais.



pav. 2 Sudėtingų klasifikavimo atvejų pavyzdžiai [12]

Kitos problemos minimos anksčiau atliktuose sprendimuose yra duomenų trūkumas. Skirtinguose regionuose auga skirtingų rūšių medžiai, tai sunkina duomenų kaupimą kiekvienai skirtingai medžių rūšiai. Lietuvos geografinėje padėtyje auga mišraus tipo miškai – spygliuočiai ir lapuočiai. Labiausiai paplitusios medžių rūšys. Didžiausią medynų ploto dalį pagal medžių rūšis užėmė pušynai (34,5 proc.), beržynai (21,9 proc.), eglynai (21,1 proc.) [1]. Iš viso šios trys medžių rūšys sudarė 77,5 proc. viso medynų ploto. Atliekant išsamesnę medžių ligų analizę, įgyvendinant sistemą, tikslinga klasifikuoti duomenis pagal skirtingas medžių rūšis, joms būdingas problemas.



### 3. Egzistuojantys sprendimai


#### 3.1. Tyrimai ir taikyti sprendimai probleminėje srityje

##### 3.1.1. Pirmas pavyzdys

„Miško medžių defoliacijos įvertinimas naudojant nuotraukas padarytas nuo žemės“. [12] Tyrimas buvo atliekamas siekiant efektyviau atlikti miško medžių defoliacijos įvertinimą, interpretuojant tai kaip vaizdo interpretavimo iššūkį. Klasifikavimo sprendime buvo naudojami konvoliuciniai neuroniniai tinklai (angl. *convolutional neural networks* arba *CNN*). Tyrimo eiga [12]:

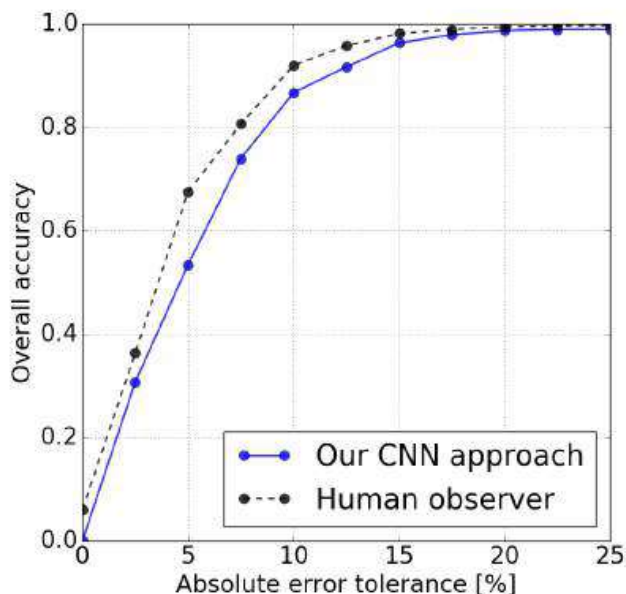
1. Ekspertai aplanko atrinktus medžius skirtinguose miškuose;
2. Padaro po vieną kiekvieno medžio spalvotą nuotrauką naudodami komercinę kamerą;
3. Kiekvienam medžiui priskiria defoliacijos įvertinimą;
4. Visos surinktos nuotraukos yra apkarpomos į kvadratą, paverčiant jas galimomis apmokyti CNN modelį;
5. Atliekamas nuotraukų apdorojimas pvz. nuotraukų apsikimas.
6. CNN modelis yra apmokomas naudojant įvertintų ir apdorotų nuotraukų poaibį;
7. Modelis ištestuojamas palyginant numatytus rezultatus su ekspertų įvertinimais.

Problemai spręsti buvo apmokomas „ResNet“ konvoliucinių neuroninių tinklų modelis. Apmokant *CNN* modelį nebuvo grupuojamos nuotraukos pagal medžio rūšį, t.y. visos turimos nuotraukos buvo sprendimas įvertina vieną sceną-nuotrauką – iš jos nustato medžio defoliacijos lygį. Prieš apmokant *CNN* modelį nuotraukos nebuvo apdorotos. *CNN* modelis buvo apmokytas su 2108 nuotraukomis, autorių teigimu tai yra per mažas kiekis duomenų, kad būtų galima apmokyti algoritmą pagal atskiras medžių rūšis (3 pav.). Taip pat, visos nuotraukos buvo atliktos ir įvertintos nuo liepos pradžios iki rugpjūčio pabaigos, kad atsiriboti nuo sezoniškumo.



pav. 3 Atlikto tyrimo duomenų kiekis suskirstytas pagal medžio rūšį

Tyrimo autorių teigimu taikytas sprendimas yra perspektyvus. „Kaip ir su dauguma (giliųjų) mašininio mokymosi metodų, modelis pasirodo gerai visose situacijose, turint pakankamai mokymo duomenų, tuo tarpu, našumas kenčia, jei mokymo pavyzdžių skaičius yra labai mažas.“ [12]




pav. 4 Žmonių ekspertų ir CNN medžių defoliacijos nustatymo rezultatai [12]

Tyrimo autoriai teigia, kad sukurtas modelis nustato medžių defoliacijos lygį tik su 8% paklaida lyginant su žmonių ekspertų vertinimu (4 pav.). Nepavykę, prasčiausiai klasifikuoti atvejai buvo su aukštos defoliacijos arba mirusio medžio nuotraukomis, autorių pateikiami sudėtingų atvejų nuotraukose (2 pav.). Pateiktuose pavyzdžiuose modelis aptiko daug žemesnį defoliacijos lygį, nei buvo įvertinta ekspertų. Autorių manymu taip atsitiko, nes klasifikatorius fone esančių medžių lapus priskirdavo negyvam medžiui. Tyrimo metu nuotraukų su labai aukšta defoliacija buvo mažai, todėl, autorių teigimu, su daugiau ir tikslesniais duomenimis modelis galėtų duoti geresnius rezultatus. Vieną iš problemų iškelgia, reiktų surinkti daugiau kokybiškų nuotraukų, duomenų, kuriose dominantis objektas, medis yra gerai atskirtas nuo aplinkos. Tyrėjai pateikia dvi gaires, kurios gali pagerinti problemos sprendimo rezultatus ateityje ir įgalintų sprendimą pritaikyti praktikoje. Pirma, siekiant pagerinti *CNN* apibendrinimo galimybes, reiktų surinkti daugiau kokybiškų duomenų. Antra, naudojant mobiliąsias programėles ir minios-piliečių mokymo projektą, būtų įmanoma surinkti didesnę duomenų kiekį iš įvairesnių ir platesnių teritorijų. [12]

### 3.1.2. Antras pavyzdys

„Vaizdu grindžiamas medžių viršūnių praradimo įvertinimas atskiriems medžiams naudojant nuotolinio orlaivio robotus.“ Atlikto eksperimento tikslas ištirti, ar sintetiškai sukurtos medžių nuotraukos gali būti naudojamos mokyti *RTCLE* (angl. *akronimas real-time crown loss estimation*) modelį, kadangi sunku surinkti didelį nuotraukų-duomenų kiekį su ekspertų įvertinimais.[13] Sprendimas yra taikomas aptikti medžių defoliaciją gaunant duomenis realiu laiku iš drono skrydžio. Taikytas sprendimas naudojo *WSL* duomenų rinkinį (tie patys duomenys naudoti pirmame pavyzdyje) ir simuliacinius-sintetinius duomenis, 3D sugeneruotus vaizdus. 90% duomenų buvo 3D sugeneruoti vaizdai ir 10% duomenų tikros nuotraukos su ekspertų įvertintais defoliacijos lygiais.

Naudojant sintetinius duomenis buvo renkamos nuotraukos iš skirtingų kampų, kameros aukščio, medis sukamas aplink savo ašį – taip vienas modelis sugeneruoja įvairius duomenų pavyzdžius (5 pav.). Tokio metodo pritaikymas įgalina sugeneruoti daug duomenų, nes vaizdai yra skaitmenizuoti – turint arba sukūrus skirtingus medžių modelius galima surinkti sudėtingų atvejų duomenų, gauti vaizdus iš tikslų kampų, atstumų.



pav. 5 3D modelių, kameros ir kampų, aukščio nustatymų [13]

Sprendimas paremtas segmentacija ir klasifikavimu naudojant *YOLO* (*you only look once*) kompiuterinės regos algoritimą. Tyrimo metu buvo sukurti du modeliai: Pirmame, medžiai klasifikuojami į standartinės 5 kategorijas kas 20% (aprašytas probleminėje srityje (2 skyrius)) pagal defoliacijos lygį. Antrame (*TSCLR* (angl. akronimas *two-step crown loss ranking*)), medžiai klasifikuojami pagal santykinį lajų nuostolį lyginant vienus su kitais (6 pav.).



pav. 6 Atlikto tyrimo segmentavimo ir defoliacijos įvertinimų palyginimai pritaikius *RTCLE* ir *TSCLR* apmokymo modelius [13]

Tyrimo autoriai teigia, kad apmokant *RTCLE* modelį vien sintetiniais duomenimis galima pasiekti pakankamai gerą medžių defoliacijos vertinimo efektyvumą. Apmokius *RTCLE* modelį kartu su ekspertų įvertintomis nuotraukomis pasiekti rezultatai yra geresni nei apmokius tik ekspertų įvertintais duomenimis, vertinant nuotraukas neįtrauktas į mokymo duomenų rinkinį. Objektų palyginimas tarp sukurtų modelių medžių defoliacijos nustatymo tikslumo lyginant su *WSL* ekspertų įvertintais duomenimis nebuvo pateiktas, nes tyrimas nustato defoliacijos lygį kiekvienam medžiui atskirai, o ekspertų įvertintuose duomenyse yra pateikiamas scenos, bendras nuotraukos vaizdo defoliacijos lygis.

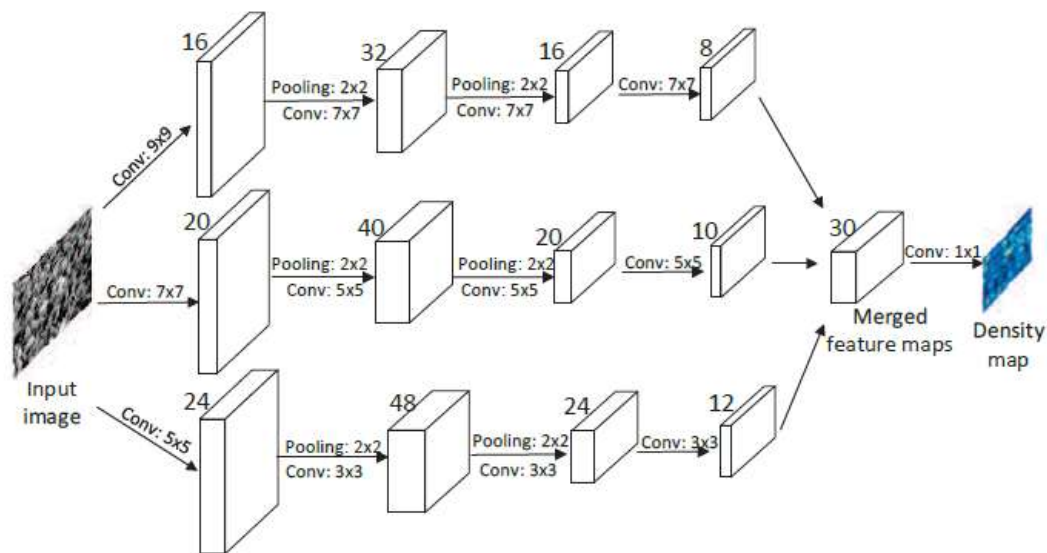
Tyrėjai apibendrina, kad kompiuterinės regos algoritmas gali būti efektyvus, patenkinamai klasifikuoti apmokytas vien tik sintetiniu duomenų rinkiniu. Tačiau, norint sukurti patikimą klasifikavimo modelį, neužtenka vien tik sintetinių ir/ar mažo kiekio realių duomenų. Todėl, teigia, kad norint sukurti patikimą modelį reikalingas didelis kiekis kokybiškų ir įvairių duomenų, kartu sujungus sintetinius duomenis galima pasiekti aukštą našumą.[13] Sintetinių duomenų problema yra

patikimam defoliacijos nustatymui reikalingas probleminės srities ekspertų įvertinimas. Siekiant tobulinti modelio efektyvumą, siūlo papildyti *RTCLE* modelio mokymo duomenų rinkinį įvairesniais vaizdais, naudojant tiek sintetinius, tiek realius duomenis, o taip pat išplėsti medžių rūšių bei geometrijų generavimą. Pateikia siūlymą, sintetiniais duomenimis sukurti sudėtingų atvejų vaizdų, kurių ypač trūksta nuotraukų rinkinyje.

## 3.2. Tyrimai ir taikyti sprendimai panašios problematikos srityse

### 3.2.1. Pirmas pavyzdys

Panašių sričių sprendimai, kurių taikytais metodais galima eksperimentuoti gali būti žmonių kiekio minioje nustatymas. Galima rasti daug įvairių sprendimų siekiančių nustatyti žmonių kiekį minioje [14][15][16], kurių taikomų metodų įgyvendinimas gali būti naudingas kuriant modelį skirtą medžių lajų tankio nustatymui. Pavyzdžiui, tyrimas žmonių kiekio minioje nustatymui iš vienos nuotraukos naudojant daugiastulpelinį konvoliucinį neuroninį tinklą.[14] Tyrimas siekia sukurti metodą, kuris gali tiksliai įvertinti minios skaičių iš atskiros nuotraukos, turinčios įvairų minios tankį ir perspektyvą. Tyrimo autoriai sprendžia kelias problemas aprašytas probleminėje srityje (2 skyrius), t.y. skalės įvertinimą, minios atskyrimą toluoje nuo arti kameros žmonių esančių. „Žmonių skaičiaus minioje nustatymas yra sudėtinga užduotis dėl okliuzijos, žmonių galvų mastelio variacijų ir nelygių žmonių pasiskirstymų.“ [16] Problemai spręsti tyrimo autoriai sukūrė *MCNN* (angl. *Multi-column Convolutional Neural Network*) *CNN* modelį (7 pav.), gebantį nustatyti skirtingus minių tankius vienoje nuotraukoje. Sukurtas modelis nebando skaičiuoti kiekvieno žmogaus galvos nuotraukoje, o sukuria minios tankio žemėlapi (pavyzdžiui, kiek žmonių viename kvadratiniam metre).



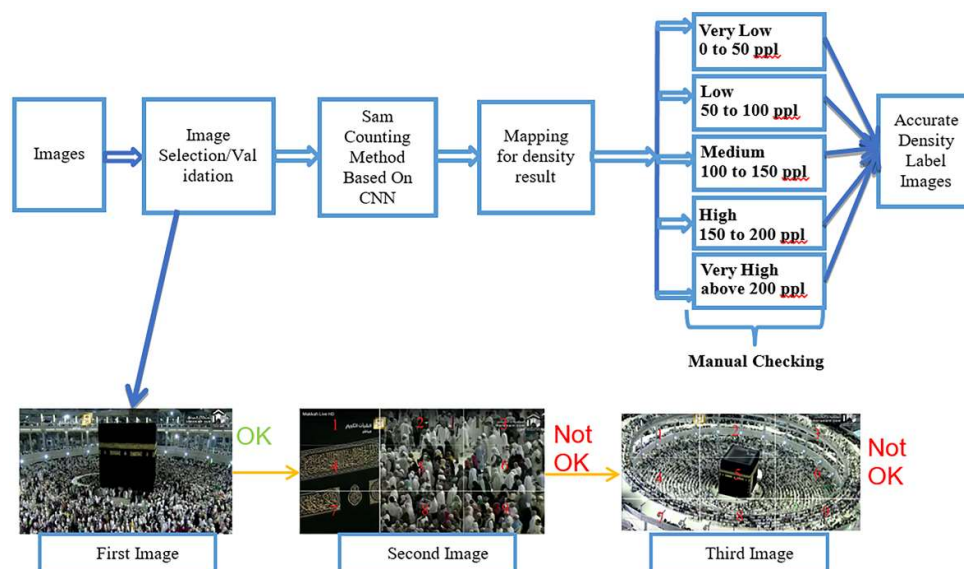
pav. 7 Daugiastulpelinio konvoliucinio neuroninio tinklo struktūra. [14]

*MCNN* architektūra leidžia naudoti įvairaus dydžio ar rezoliucijos įvesties paveikslėlius. Naudojant filtrus su skirtingo dydžio priimančiomis sritimis (angl. *receptive fields*), kiekvieno stulpelinio CNN išmoka savybes, prisitaikančias prie žmonių/galvų dydžio kaitos dėl perspektyvos poveikio arba paveikslėlio rezoliucijos.

Tyrimo autoriai teigia, kad daugiastulpelinio konvoliucinio neuroninio tinklo modelis geba nustatyti tikslų minios tankumą iš įvairių perspektyvų. Tyrėjų teigimu, MMNet modelis, pasižymi labai dideliu efektyvumu ir puikiai susitvarko su skirtingomis minios tankio variacijomis.

### 3.2.2. Antras pavyzdys

Minios tankio klasifikavimo sprendimas. [17] Tyrimo autoriai aprašo jų sprendimo metodą pritaikius konvoliuciniu neuroninius tinklus sprendžiant minios tankio nustatymo, klasifikavimo problemą. Šis sprendimas yra aktualus, nes sprendžia panašią problemą susijusią su tankio nustatymu. Sprendžiant problemą duomenys yra klasifikuojami į keturias kategorijas, priklausomai nuo žmonių tankio aikštėje. Taikytas sprendimas yra orientuotas į duomenis (angl. *data-centric*). Prieš mokant nuotraukos yra atrinkamos, kad dominanti erdvė būtų nuotraukos centre ir tinkamame nuotolyje t.y. modelis apmokomas tik su nuotraukomis atitinkančiomis fotografuotą kampa, priartinimą (7 pav.).



pav. 8 Žmonių minios tankio nustatymo sistemos struktūrinė schema [17]

Autoriai teigia, kad jų sukurtas modelis geba nustatyti per daug tankiai užpildytą erdvę 100% tikslumu naudojant jų duomenų rinkinį ir 97% tikslumu naudojant „ResNet“ neuroninių tinklų modelį. Tyrimas demonstruoja, kad duomenimis paremtas klasifikavimo sprendimas buvo efektyvus panašios problematikos užduotyje.

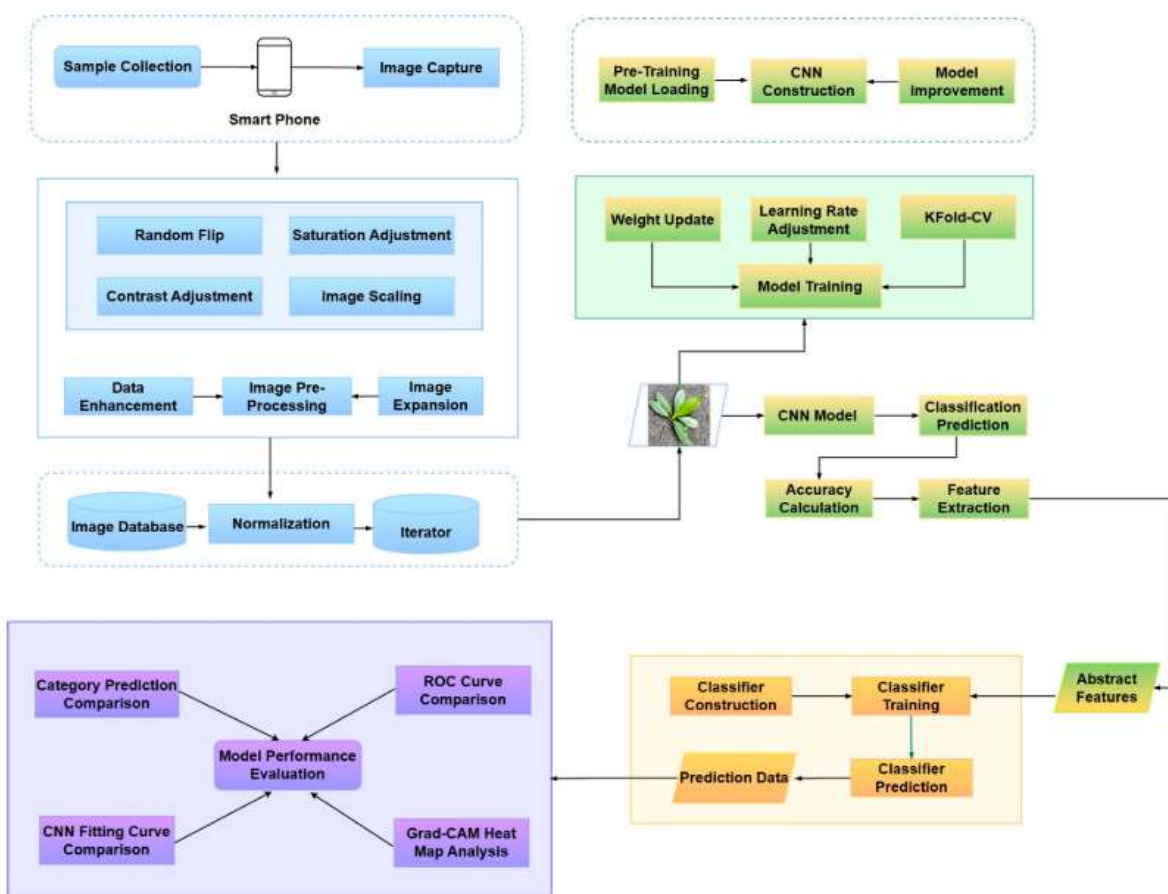
### 3.2.3. Trečias pavyzdys

"Lapų ir šakelių atpažinimas naudojant gilųjų mokymąsi ir kombinuotus klasifikavimo algoritmus." [18] Tyrimas sprendžia medžių rūšių klasifikavimo, automatinio atpažinimo problemą naudojant nuotraukas. Sprendimas nustato medžių rūšis naudojant atskiras lapų nuotraukas. Tyrimo eiga paprasta (9 pav.):

1. renkami duomenys-nuotraukos, jos apdorojamos geresniam pritaikymui – atliekama skalės, kontrasto standartizacija;
2. Apmokomi konvoliuciniai neuroniniai tinklai;



3. Klasifikavimo modeliai ištestuojami naudojant duomenis nenaudotus mokymo metu;
4. Atliekama rezultatų analizė.



pav. 9 Medžių klasifikavimo sistemos struktūrinė schema [18]

Surinkti ir apdoroti duomenys buvo apmokinti skirtingais neuroninių tinklų modeliais. Geriausias tirtas modelis pasiekė 99,86% tikslumą atpažįstant 21 medžių rūšis. Autorių įgyvendinta sistema geba efektyviai klasifikuoti medžių rūšis naudojant lapų, šakų nuotraukas. Siekiant tobulinti modelį, tyrėjai įvardina panašias problematikas ir pasiūlymus kaip pirmo probleminės srities tyrimo autoriai (3.1.1 skyrius). Tyrėjai iškelia poreikį plėsti medžių rūšių skaičių duomenų rinkinyje, įtraukti daugiau medžių savybių, siekiant geriau atpažinti ir įvertinti tų rūšių bruožus. Taip pat, siekiant gauti geresnius rezultatus ir efektyvesnę mokymąsi siūlo sukurti medžių rūšių identifikavimo mobilią programėlę.

### 3.3. Sprendimų apibendrinimas

Probleminės srities sprendimų autoriai įvardija duomenų trūkumą kaip pagrindinę problemą ir teigia, kad daugiau kokybiškai sužymėtų duomenų pagerintų neuroninių tinklų kokybę. Duomenys yra pagrindinis faktorius, lemiantis konvoliucinių neuroninių tinklų *CNN* veikimą. Efektyvus duomenų rinkimas ir tinkamas jų apdorojimas yra esminiai žingsniai siekiant sukurti patikimus ir tikslus modelius. Modelio veikimas galiausiai yra apribotas mokymo duomenų kokybe. Tačiau gauti aukštos kokybės mokymo duomenų yra ilgas ir brangus procesas. [19]. Pagrindinės įvardintos sritys, kurios gali teigiamai paveikti klasifikavimo modelį:

- Surinkti daugiau ekspertų įvertintų nuotraukų;
- Surinkti įvairesnių, sudetingų atvejų duomenų;
- Galimas sintetinių duomenų panaudojimas;
- Modelio apmokymas atskiriant skirtingus medžius;
- Mobilios programėlės skirtos duomenų rinkimui kūrimas.

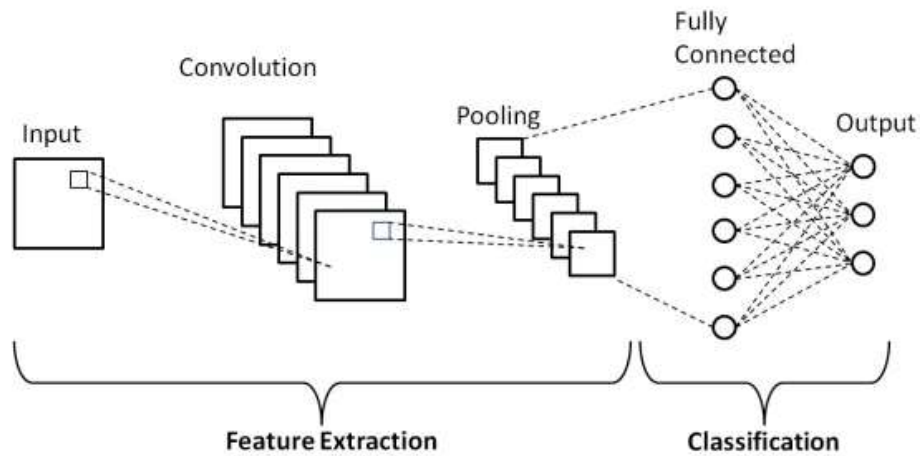
Tyrimuose nebuvo nustatomas medžio tipas, tyrimų autoriai teigia, kad turint pakankamai duomenų, kad galima būtų apmokyti neuroninius tinklus atskiriant medžių rūšis, tai gali reikšmingai pagerinti klasifikavimo kokybę. Antrame panašių sprendimų pavyzdyje (3.2.2 skyrius) autoriai teigia pasiekę labai aukštą klasifikavimo tikslumą taikydami į duomenis orientuotą metodologiją. Trečiame panašios problematikos pavyzdyje (3.2.3 skyrius) pateikiamas pavyzdys gebantis efektyviai klasifikuoti medžių rūšis naudojant medžių lapų ir šakelių nuotraukas. Tyrimo autoriai įvardija tas pačias problemas siekiant tobulinti klasifikavimą. Siekiant surinkti naštų ir įvairių duomenų rinkinį egzistuoja kitos, natūralių veiksnių problemos, kurios gali lemti modelio netikslumus:

- Skirtingos medžių rūšys;
- Medžiai keičia lapų spalvą dėl sezoniškumo;
- Medžiai praranda lapus žiemos metu;
- Apsnigtos medžių šakos;
- kt.

Šioms problemoms spresti analizuotų sprendimų autoriai naudojo, rinko duomenis pasirinktais mėnesiais – šiltuoju metų laiku. Tačiau, teigia, siekiant sukurti patikimą modelį, kurį galima būtų pritaikyti praktiškai, šių problemų sprendimas yra aktualus.

#### 4. Konvoliuciniai neuroniniai tinklai

Konvoliuciniai neuroniniai tinklai yra viena iš populiariausių mašininio mokymosi kategorija. Konvoliucinių neuroninių tinklų pagrindinė idėja yra išmokyti vietines savybes iš įvesties aukštesniuose sluoksniuose ir jas sujungti į sudėtingesnes savybes žemesniuose sluoksniuose. [20] Konvoliuciniai neuroniniai tinklai yra ypač plačiai naudojami atrasti, „išmokyti“ atsikartojančias sekas iš didelių matmenų (angl. *high-dimensional*) duomenų pvz. paveikslukų, vaizdo įrašų medžiagos [21] ir yra labai efektyvūs įvairiose srityse pvz. vaizdų klasifikavimas, objektų aptikimas, kalbos atpažinimas, natūralios kalbos apdorojimas ir medicininių vaizdų analizė. [20] *CNN* veikia nustatant ryšį tarp įvesties duomenų ir norimo rezultato bei išimant išmokus šio ryšio bruožus tinklo filtrų svoriuose [22].



pav. 10 Pagrindinės konvoliucinių neuroninių tinklų architektūros dalys

Pagrindinės dalys iš kurių susideda *CNN* (10 pav.):

**Konvoliucinis sluoksnis** (angl. *Convolutional layer*): Tai yra viena iš pagrindinių konvoliucinių neuroninių tinklų (*CNN*) dalių. Šiame sluoksnyje atliekama konvoliucija, kurios metu taikomi filtrai arba spūdziai (angl. *kernels*) į įvesties duomenis, norint gauti skirtingų požymių iš paveikslėlių ar kitų įvesties duomenų. Tai padeda išgryninti svarbias savybes, pavyzdžiui, linijas, kampus, ar kitas formas, kurios padeda tinklui atpažinti ir suprasti įvesties duomenų struktūrą. Konvoliucija yra matematinė operacija, atliekama dviem funkcijomis ir užrašoma kaip  $(f * g)$ , kur  $f$  ir  $g$  yra dvi funkcijos. Konvoliucijos operacijos išvestis domenui  $n$  apibrėžiama taip [20]:

$$(f * g)(n) = \sum_m f(m)g(n - m)$$

**Aktyvavimo sluoksnis** (angl. *Activation layer*): Paprastai sekantis konvoliuciniam sluoksniui, įvedama netiesiškumą į tinklą, dažniausiai pasiekiami per aktyvavimo funkcijas, tokias kaip *ReLU* (Tiesinės lygties tiesinė vienetų funkcija). dažnai naudojamos trys aktyvacijos funkcijos (6 pav.): Sigmoidinė funkcija:

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$


Tiesinė vienetų (*ReLU*) funkcija (angl. *rectified linear unit*) apibrėžiama:



$$f(x) = \max(0, x)$$

Parametrizuota *ReLU* (*PReLU*) funkcija [22] apibrėžiama:

$$f(x) = \max(0.1x; x).$$



pav. 11 Trys *CNN* aktyvavimo funkcijos: sigmoidinė kairėje, tiesinė vienetų viduryje ir parametrizuota *ReLU* dešinėje [22]

**Grupavimo sluoksnis** (angl. *Pooling layer*): Šis sluoksnis dažniausiai naudojamas po konvoliucinio sluoksnio. Jo tikslas sumažinti požymių (feature map) dydį, sumažindamas kiekvieno regiono arba požymio reikšmių rinkinį į vieną bendrą reikšmę. Tai padeda sumažinti skaičiavimo laiką, mažinant išmatavimų kiekį ir tuo pačiu išlaikant svarbias informacijos savybes.

**Partijos normalizacijos sluoksnis** (angl. *Batch normalization layer*): Padeda normalizuoti kiekvieno sluoksnio įvestis, mažinant vidinį kovariacijos poslinkį, pagerinant visą apmokymo stabilumą ir greitį.

**Išlyginimo sluoksnis** (angl. *Flatten layer*): Transformuoja įvestį į vienmatį masyvą, dažniausiai naudojamas prieš visiškai sujungtus sluoksnius.

**Visiškai sujungtas sluoksnis** (angl. *Fully connected layer*): Šiame sluoksnyje kiekvienas neuronas yra sujungtas su visais ankstesnių sluoksnių neuronais, leiddami modeliui išmokti sudėtingesnes požymių hierarchijas ir atlikti galutinį sprendimą arba klasifikavimą.

**Atsijungimo sluoksnis** (angl. *Dropout layer*): Naudojamas apsaugoti nuo permokymo atsitiktinai išmetant tam tikrą įvesties neuronų dalį per treniravimą. Tai sumažina priklausomybę tarp neuronų mokymosi metu, padedant išvengti permokymo.

Šie sluoksniai ir jų funkcijos sudaro konvoliucinius neuroninius tinklus, kurie yra naudingi vaizdų atpažinimo, objektų aptikimo ir kitų užduočių sprendime, kai nagrinėjama struktūrizuota įvesties informacija, išgrynindama svarbias savybes ir naudodama jas sprendimų priėmimo.

Konvoliucinių neuroninių tinklų modelius galima apmokyti keliais būdais, kiekvienas suteikia skirtingų privalumų:

- **Prižiūrimas mokymas** (angl. *Supervised learning*): standartinis pasirinkimas mašiniame mokyme, apmokymo metu neuroniniam tinklui pateikiami duomenys ir norimi rezultatai yra žinomi, su žymėmis (angl. *labels*), modelis mokosi lygindamas nuspėjamą rezultatą su žinomomis žymėmis. Šis modelis taikytas pirmajame egzistuojančių sprendimų pavyzdyje (3.1.1 skyrius).

- **Neprižiūrimas mokymas** (angl. *Unsupervised learning*): Tinklui yra pateikiami duomenys be aiškių žymių arba rezultatų, ir jis mokosi iš jų išgrynindamas savybes arba struktūras. Šis modelis taikytas antrame egzistuojančių sprendimų pavyzdyje (3.1.2 skyrius).
- **Pusiau prižiūrimas mokymas** (angl. *Weak supervision* arba *semi-supervised learning*): Šiuo metodu tinklui yra pateikiami duomenys, kuriuose dalis informacijos yra žymima, o kitos dalys ne.
- **Stiprinimo mokymas** (angl. *Reinforcement learning*): Tinklas mokomas atliekant veiksmus siekiant maksimizuoti apdovanojimą arba baudą remiantis atliktomis veiksmų sekos rezultatais.
- **Perkeliamasis mokymas** (angl. *Transfer learning*): Tai metodas, kai tinklą išankstiniu būdu apmokoma vienu uždaviniu, ir gautos žinios arba savybės yra pernaudojamos arba pritaikomos kitam, panašiam uždaviniui. Tai leidžia greičiau ir efektyviau pritaikyti tinklą naujiems uždaviniams, kai yra riboti duomenys ar resursai. Šis modelis taikytas antrame egzistuojančių sprendimų pavyzdyje (3.1.2 skyrius) apmokant modelį „sintetiniais“, 3D medžių vaizdais, o vėliau, tikromis nuotraukomis su žymėmis.

Kiekvienas iš šių metodų turi savo privalumų, o tinkamiausias priklauso nuo konkrečių duomenų, uždavinio ir turimų išteklių. Skirtingi apmokymo metodai gali suteikti įvairių privalumų ir padėti geriau prisitaikyti prie skirtingų situacijų.

Yra labai daug konvoliucinių neuroninių tinklų klasifikavimo modelių, šie yra populiariausi arba turėję daugiausiai įtakos bendram *CNN* vystymesi:

- AlexNet [23]
- VGGNet [24]
- GoogLeNet/Inception [25]
- ResNet [26]
- DenseNet [27]
- YOLO [28]

Visi šie neuroninių tinklų modeliai pristatė naujas architektūras ir inovacijas, praturtindami kompiuterinės regos ir objektų atpažinimo sritis, ir yra galingi ir efektyvūs įrankiai klasifikavimo problemų sprendime.

## **5. Išvados**

1. Apžvelgta medžių defoliacijos ir ligų nustatymo problematika
2. Išnagrinėti 2 egzistuojantys medžių defoliacijos klasifikavimo sprendimai
3. Išnagrinėti 3 sprendimai sprendžiantys panašios problematikos uždavinius
4. Nustatytos pagrindinės sritys kurių realizavimas gali veiksmingai spręsti medžių defoliacijos klasifikavimo uždavinį
5. Išanalizuoti konvoliucinių neuroninių tinklų modelių pagrindai

## Literatūros sąrašas

- [1] Valstybinė miškų tarnyba, “Šalies miškų rodikliai ir jų kaita,” Kaunas, 2020.
- [2] R. Beinortas, “Medienos produktų importo ir eksporto 2020 m. analizė,” Vilnius, 2020.
- [3] K. Budnik, J. Byrtek, B. Skrabanek, and J. Wajs, “AI-Accelerated Decision Making in Forest Management,” in *IOP Conference Series: Earth and Environmental Science*, Institute of Physics, 2023. doi: 10.1088/1755-1315/1189/1/012030.
- [4] P. Co-ordinating Centre of ICP Forests, “Forest Condition in Europe The 2021 Assessment ICP Forests Technical Report under the UNECE Convention on Long-range Transboundary Air Pollution (Air Convention) FOREST CONDITION IN EUROPE: The 2021 Assessment,” 2021. doi: 10.3220/ICPTR1624952851000.
- [5] V. Stakėnas, I. Varnagirytė-Kabašinskienė, and A. Kabašinskas, “A methodological approach for the assessment of basic crown parameters in scots pine stands,” *Balt For*, vol. 27, no. 1, 2021, doi: 10.46490/BF551.
- [6] A. 1975- Michel, W. Seidling, Johann Heinrich von Thünen-Institut, and N. und L. Bundesforschungs- und Ausbildungszentrum für Wald, “Forest Condition in Europe 2014 technical report of ICP forests; report under the UNECE Convention on Long-Range Transboundary Air Pollution (CLRTAP),” Vienna, 2014.
- [7] Čapkauskas G., “Gamtiniai medynų vystymosi trūkumai: medžių pažeidžiamumas ir lajų defoliacijos rizika,” Aleksandro Stulginskio universitetas, Kaunas, 2016.
- [8] Lakatos F. and Mirtchev S., “Main pests of pine forests in south east Europe,” Budapest, 2014.
- [9] Federal Research Centre for Forestry and Forest Products (BFH), “Convention on Long-Range Transboundary Air Pollution, International Co-operative Programme on Assessment and Monitoring of Air Pollution Effects on Forests, and European Union Scheme on the Protection of Forests Against Atmospheric Pollution prepared by: Federal Research Centre for Forestry and Forest Products (BFH),” Geneva and Brussels, 2003.
- [10] S. Solberg and L. Strand, “Crown density assessments, control surveys and reproducibility,” 1999. doi: 10.1023/A:1005980326079.
- [11] N. Mizoue, “Japan Society of Forest Planning NII-Electronic Library Service JapanSociety of Forest Planning CROCO: Semi-automatic Image Analysis System fbr Crown Condition Assessment in Forest Health Monitoring,” 2022. doi: 10.20659/jfp.8.1\_17.
- [12] U. Kälın, N. Lang, C. Hug, A. Gessler, and J. D. Wegner, “Defoliation estimation of forest trees from ground-level images,” 2018, doi: 10.1101/441733.
- [13] B. Ho, B. B. Kocer, and M. Kovac, “Vision based crown loss estimation for individual trees with remote aerial robots,” *ISPRS Journal of Photogrammetry and Remote Sensing*, vol. 188, pp. 75–88, Jun. 2022, doi: 10.1016/j.isprsjprs.2022.04.002.
- [14] Y. Zhang, D. Zhou, S. Chen, S. Gao, and Y. Ma, “Single-Image Crowd Counting via Multi-Column Convolutional Neural Network,” Las Vegas: IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016. doi: 10.1109/CVPR.2016.70.
- [15] Y. Chen, J. Yang, B. Chen, and S. Du, “Counting Varying Density Crowds Through Density Guided Adaptive Selection CNN and Transformer Estimation,” Jun. 2022, doi: 10.1109/TCSVT.2022.3208714.
- [16] L. Dong, H. Zhang, Y. Ji, and Y. Ding, “Crowd counting by using multi-level density-based spatial information: A Multi-scale CNN framework,” *Inf Sci (N Y)*, vol. 528, pp. 79–91, Aug. 2020, doi: 10.1016/j.ins.2020.04.001.

- [17] M. R. Bhuiyan *et al.*, “A deep crowd density classification model for Hajj pilgrimage using fully convolutional neural network,” *PeerJ Comput Sci*, vol. 8, 2022, doi: 10.7717/peerj-cs.895.
- [18] X. Sun, L. Xu, Y. Zhou, and Y. Shi, “Leaves and Twigs Image Recognition Based on Deep Learning and Combined Classifier Algorithms,” *Forests*, vol. 14, no. 6, Jun. 2023, doi: 10.3390/f14061083.
- [19] S. Liu and R. Vetter, “Enhancing Training Data Quality With Visual Analytics,” *Computer (Long Beach Calif)*, vol. 56, no. 11, pp. 4–6, Nov. 2023, doi: 10.1109/MC.2023.3304568.
- [20] M. A. Wani, F. A. Bhat, S. Afzal, and A. I. Khan, “Basics of Supervised Deep Learning,” in *Studies in Big Data*, vol. 57, Springer Science and Business Media Deutschland GmbH, 2020, pp. 13–29. doi: 10.1007/978-981-13-6794-6\_2.
- [21] Khan Salman, Rahmani Hossein, Afaq Ali Shah Syed, and Bennamoun Mohammed, *A Guide to Convolutional Neural Networks for Computer Vision*. Springer Nature Switzerland AG, 2022. doi: 10.1007/978-3-031-01821-3.
- [22] C.-C. J. Kuo, “Understanding Convolutional Neural Networks with A Mathematical Model,” 2016. [Online]. Available: <http://yann.lecun.com/exdb/mnist/>
- [23] A. Krizhevsky, I. Sutskever, and G. E. Hinton, “ImageNet Classification with Deep Convolutional Neural Networks,” F. Pereira, C. J. Burges, L. Bottou, and K. Q. Weinberger, Eds., 2012. [Online]. Available: <http://code.google.com/p/cuda-convnet/>
- [24] K. Simonyan and A. Zisserman, “Very Deep Convolutional Networks for Large-Scale Image Recognition,” Sep. 2014, [Online]. Available: <http://arxiv.org/abs/1409.1556>
- [25] C. Szegedy *et al.*, “Going Deeper with Convolutions,” Sep. 2014, [Online]. Available: <http://arxiv.org/abs/1409.4842>
- [26] K. He, X. Zhang, S. Ren, and J. Sun, “Deep Residual Learning for Image Recognition,” Dec. 2015, [Online]. Available: <http://arxiv.org/abs/1512.03385>
- [27] G. Huang, Z. Liu, L. van der Maaten, and K. Q. Weinberger, “Densely Connected Convolutional Networks,” Aug. 2016, [Online]. Available: <http://arxiv.org/abs/1608.06993>
- [28] J. Terven and D. Cordova-Esparza, “A Comprehensive Review of YOLO: From YOLOv1 and Beyond,” Apr. 2023, [Online]. Available: <http://arxiv.org/abs/2304.00501>